Performance

Techniques avancées en programmation statistique R

Patrick Fournier

Automne 2020

Université du Québec à Montréal

Introduction

→ "Il ne faut pas faire de boucles en R car elles sont lentes."

- → "Il ne faut pas faire de boucles en R car elles sont lentes."
- → "R est un mauvais language de programmation car il n'est pas performant."

- → "Il ne faut pas faire de boucles en R car elles sont lentes."
- → "R est un mauvais language de programmation car il n'est pas performant."
- → "Python, Julia, C++, SAS, ... est meilleur que R car il est plus performant."

- → "Il ne faut pas faire de boucles en R car elles sont lentes."
- → "R est un mauvais language de programmation car il n'est pas performant."
- → "Python, Julia, C++, SAS, ... est meilleur que R car il est plus performant."
- → "Il faut implémenter les parties critiques du programme en C/C++/Fortran et le reste en R."

- → "Il ne faut pas faire de boucles en R car elles sont lentes."
- → "R est un mauvais language de programmation car il n'est pas performant."
- → "Python, Julia, C++, SAS, ... est meilleur que R car il est plus performant."
- → "Il faut implémenter les parties critiques du programme en C/C++/Fortran et le reste en R."

→ ...

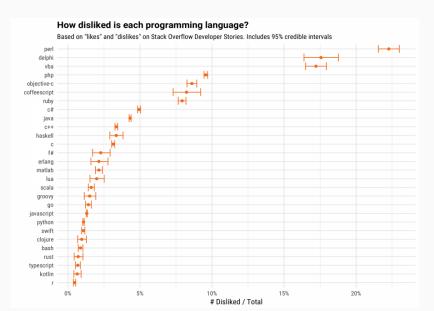
R vs. autres languages [2]

Sep 2020	Sep 2019	Change	Programming Language	Ratings	Change
1	2	^	С	15.95%	+0.74%
2	1	•	Java	13.48%	-3.18%
3	3		Python	10.47%	+0.59%
4	4		C++	7.11%	+1.48%
5	5		C#	4.58%	+1.18%
6	6		Visual Basic	4.12%	+0.83%
7	7		JavaScript	2.54%	+0.41%
8	9	^	PHP	2.49%	+0.62%
9	19	*	R	2.37%	+1.33%
10	8	•	SQL	1.76%	-0.19%
11	14	^	Go	1.46%	+0.24%
12	16	*	Swift	1.38%	+0.28%
13	20	*	Perl	1.30%	+0.26%
14	12	•	Assembly language	1.30%	-0.08%
15	15		Ruby	1.24%	+0.03%
16	18	^	MATLAB	1.10%	+0.04%
17	11	*	Groovy	0.99%	-0.52%
18	33	*	Rust	0.92%	+0.55%
19	10	*	Objective-C	0.85%	-0.99%
20	24	*	Dart	0.77%	+0.13%

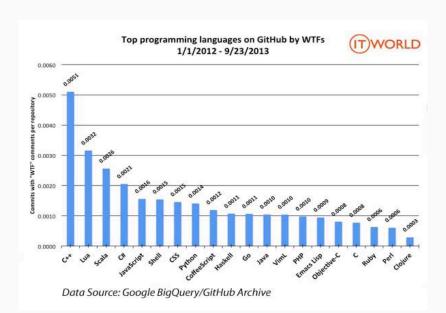
R à travers le temps [2]

Highest Position (since 2007): #8 in Aug 2020 ¥ Lowest Position (since 2007): #73 in Dec 2008 TIOBE Index for R Source: www.tiobe.com 2012 2018 2016 2020

Langages détestés [3]



Langage par proportion de WTFs [1]



Le terrible secret des variables en R

Variable

Symbole représentant un espace mémoire.

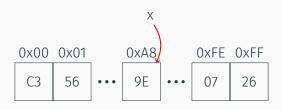
Variable

Symbole représentant un espace mémoire.



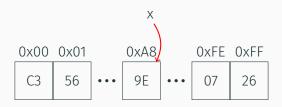
Variable

Symbole représentant un espace mémoire.



Variable

Symbole représentant un espace mémoire.



Remarque

Selon cette définition, une variable n'a pas besoin de pouvoir varier!

Une petite expérience

Voir exemples.ipynb

Mutable

Il est possible de changer la valeur contenue dans la case mémoire associée à une variable.

Mutable

Il est possible de changer la valeur contenue dans la case mémoire associée à une variable.

→ Approche associée à la programmation impérative.

Mutable

Il est possible de changer la valeur contenue dans la case mémoire associée à une variable.

→ Approche associée à la programmation impérative.

Immutable

Une fois qu'une valeur est stockée en mémoire, il n'est pas possible de modifier cette valeur.

Mutable

Il est possible de changer la valeur contenue dans la case mémoire associée à une variable.

→ Approche associée à la programmation impérative.

Immutable

Une fois qu'une valeur est stockée en mémoire, il n'est pas possible de modifier cette valeur.

→ Pour donner l'illusion de la modification, on associe simplement la variable à une autre case mémoire.

Mutable

Il est possible de changer la valeur contenue dans la case mémoire associée à une variable.

→ Approche associée à la programmation impérative.

Immutable

Une fois qu'une valeur est stockée en mémoire, il n'est pas possible de modifier cette valeur.

- → Pour donner l'illusion de la modification, on associe simplement la variable à une autre case mémoire.
- → Approche associée à la programmation fonctionnelle.

Mutable

Il est possible de changer la valeur contenue dans la case mémoire associée à une variable.

→ Approche associée à la programmation impérative.

Immutable

Une fois qu'une valeur est stockée en mémoire, il n'est pas possible de modifier cette valeur.

- → Pour donner l'illusion de la modification, on associe simplement la variable à une autre case mémoire.
- → Approche associée à la programmation fonctionnelle.

Et R?

C'est compliqué.

→ R associe à (presque) chaque objet un compteur.

- → R associe à (presque) chaque objet un compteur.
 - → Exception: les objets de type environment, qui sont toujours mutables.

- → R associe à (presque) chaque objet un compteur.
 - Exception: les objets de type environment, qui sont toujours mutables.
- → Déclaration de la variable : compteur initialisé à 1.

- → R associe à (presque) chaque objet un compteur.
 - → Exception : les objets de type environment, qui sont toujours mutables.
- → Déclaration de la variable : compteur initialisé à 1.
- → Deux manières d'incrémenter le compteur :

- → R associe à (presque) chaque objet un compteur.
 - → Exception : les objets de type environment, qui sont toujours mutables.
- → Déclaration de la variable : compteur initialisé à 1.
- → Deux manières d'incrémenter le compteur :
 - → ajouter une référence vers la variable et

- → R associe à (presque) chaque objet un compteur.
 - Exception: les objets de type environment, qui sont toujours mutables.
- → Déclaration de la variable : compteur initialisé à 1.
- → Deux manières d'incrémenter le compteur :
 - → ajouter une référence vers la variable et
 - utiliser la variable comme argument pour une fonction non-primitive (et certaines fonctions primitives).

- - → Si le compteur vaut 1, la variable est mutée.

- - → Si le compteur vaut 1, la variable est mutée.
 - → Sinon, une nouvelle variable est crée.

- - → Si le compteur vaut 1, la variable est mutée.
 - → Sinon, une nouvelle variable est crée.
- → Tout cela devient vite compliqué!

- → Lorsque vient le temps de modifier une variable, deux possibilités :
 - → Si le compteur vaut 1, la variable est mutée.
 - → Sinon, une nouvelle variable est crée.
- → Tout cela devient vite compliqué!
- De manière générale, un code qui suppose que les variables sont immutables sera plus performant.

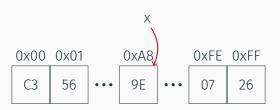
- → Lorsque vient le temps de modifier une variable, deux possibilités :
 - → Si le compteur vaut 1, la variable est mutée.
 - → Sinon, une nouvelle variable est crée.
- → Tout cela devient vite compliqué!
- → De manière générale, un code qui suppose que les variables sont immutables sera plus performant.
- De plus, bien qu'il soit possible d'exploiter la mutabilité pour obtenir des gains de performances, ils sont habituellement marginaux.

- - → Si le compteur vaut 1, la variable est mutée.
 - → Sinon, une nouvelle variable est crée.
- → Tout cela devient vite compliqué!
- → De manière générale, un code qui suppose que les variables sont immutables sera plus performant.
- → De plus, bien qu'il soit possible d'exploiter la mutabilité pour obtenir des gains de performances, ils sont habituellement marginaux.
- Cela étant dit, un cas important où la mutabilité peut être exploitée est la préallocation de mémoire

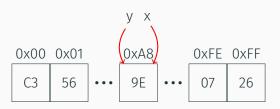
```
1 > x <- 158
2 > y <- x
3 > x <- 86
```



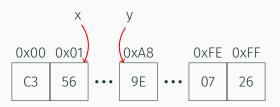
```
1 > x <- 158
2 > y <- x
3 > x <- 86
```



```
1 > x <- 158
2 > y <- x
3 > x <- 86
```



```
1 > x <- 158
2 > y <- x
3 > x <- 86
```



Exemple: préallocation

Voir exemples.ipynb

Que s'est-il passé?

Que s'est-il passé?

for

Assigne directement une valeur à un emplacement mémoire bien déterminé.

Que s'est-il passé?

for

Assigne directement une valeur à un emplacement mémoire bien déterminé.

replicate

-> sapply -> lapply -> code compilé

Que s'est-il passé?

for

Assigne directement une valeur à un emplacement mémoire bien déterminé.

replicate

-> sapply -> lapply -> code compilé

Le code à exécuter est tellement simple que l'overhead associé à l'appel de code externe tue la performance!

Fonction

Fonction

Ensemble d'instructions permettant l'exécution d'une tâche.

→ En R, fonction = objet de première classe (comme un vecteur, une liste...)

Fonction

- → En R, fonction = objet de première classe (comme un vecteur, une liste...)
- → On peut assigner un symbole à une fonction...

Fonction

- → En R, fonction = objet de première classe (comme un vecteur, une liste...)
- → On peut assigner un symbole à une fonction...
- → Ou pas! On parle alors de fonction lambda ou de fonction anonyme.

Fonction

- → En R, fonction = objet de première classe (comme un vecteur, une liste...)
- → On peut assigner un symbole à une fonction...
- → Ou pas! On parle alors de fonction lambda ou de fonction anonyme.
 - Souvent utilisées dans les fonctionnelle : apply, Reduce, Filter...

→ En R, une fonction est composée de 3 éléments :

→ En R, une fonction est composée de 3 éléments :
formals
une liste d'arguments,

```
    En R, une fonction est composée de 3 éléments :
        formals
            une liste d'arguments,
            body
            du code et
```

En R, une fonction est composée de 3 éléments :
 formals
 une liste d'arguments,
 body
 du code et
 environment

un ensemble de symboles associés à des valeurs.

→ En R, une fonction est composée de 3 éléments :

formals

une liste d'arguments,

body

du code et

environment

un ensemble de symboles associés à des valeurs.

Ces trois composantes peuvent être examinées à l'aide des fonctions formals, body et environment respectivement.

Voir exemples.ipynb

→ À quelques détails près, un environment peu être vu comme une simple liste.

- → À quelques détails près, un environment peu être vu comme une simple liste.
- → En particulier, presque tout environment possède un environment parent.

- → À quelques détails près, un environment peu être vu comme une simple liste.
- → En particulier, presque tout environment possède un environment parent.
 - Le seul orphelin est R_EmptyEnv, l'ancêtre de tous les environments.

- → À quelques détails près, un environment peu être vu comme une simple liste.
- → En particulier, presque tout environment possède un environment parent.
 - Le seul orphelin est R_EmptyEnv, l'ancêtre de tous les environments.
 - → Un autre environment important est R_GlobalEnv où ont lieu toutes les opérations situées à l'extérieur d'une fonction.

- → À quelques détails près, un environment peu être vu comme une simple liste.
- → En particulier, presque tout environment possède un environment parent.
 - Le seul orphelin est R_EmptyEnv, l'ancêtre de tous les environments.
 - → Un autre environment important est R_GlobalEnv où ont lieu toutes les opérations situées à l'extérieur d'une fonction.
- → Lorsqu'un symbole est appelé,

- → À quelques détails près, un environment peu être vu comme une simple liste.
- → En particulier, presque tout environment possède un environment parent.
 - Le seul orphelin est R_EmptyEnv, l'ancêtre de tous les environments.
 - → Un autre environment important est R_GlobalEnv où ont lieu toutes les opérations situées à l'extérieur d'une fonction.
- → Lorsqu'un symbole est appelé,
 - → R le cherche dans l'environment courrant.

- → À quelques détails près, un environment peu être vu comme une simple liste.
- → En particulier, presque tout environment possède un environment parent.
 - Le seul orphelin est R_EmptyEnv, l'ancêtre de tous les environments.
 - → Un autre environment important est R_GlobalEnv où ont lieu toutes les opérations situées à l'extérieur d'une fonction.
- → Lorsqu'un symbole est appelé,
 - → R le cherche dans l'environment courrant.
 - S'il ne le trouven pas, il le cherche dans le parent de cet environment et ainsi de suite.

- → À quelques détails près, un environment peu être vu comme une simple liste.
- → En particulier, presque tout environment possède un environment parent.
 - → Le seul orphelin est R_EmptyEnv, l'ancêtre de tous les environments.
 - → Un autre environment important est R_GlobalEnv où ont lieu toutes les opérations situées à l'extérieur d'une fonction.
- → Lorsqu'un symbole est appelé,
 - → R le cherche dans l'environment courrant.
 - → S'il ne le trouven pas, il le cherche dans le parent de cet environment et ainsi de suite.
 - → Arrivé à R_EmptyEnv, R sait que le symbole n'est pas défini.

<- (Assignment)

Crée un symbole dans l'environment dans lequel il est appelé.

<- (Assignment)

Crée un symbole dans l'environment dans lequel il est appelé.

<<- (Super assignment)

"Modifie" la valeur d'un symbole situé dans un des environment parent.

<- (Assignment)

Crée un symbole dans l'environment dans lequel il est appelé.

<<- (Super assignment)

"Modifie" la valeur d'un symbole situé dans un des environment parent.

→ Si un symbole n'est pas défini, <<- le créera dans R_GlobalEnv.
</p>

<- (Assignment)

Crée un symbole dans l'environment dans lequel il est appelé.

<<- (Super assignment)

"Modifie" la valeur d'un symbole situé dans un des environment parent.

- → Si un symbole n'est pas défini, <<- le créera dans R GlobalEnv.
 </p>
- → Si le symbole est une variable, on parle alors de variable globale.

Portée lexicale

→ À chaque fois qu'une fonction est appelée, un nouvel environment est construit.

Portée lexicale

- → À chaque fois qu'une fonction est appelée, un nouvel environment est construit.
- ~ Comme les environments sont ordonnés, cela permet l'implémentation du concept de *portée lexicale*.

Portée lexicale

- → À chaque fois qu'une fonction est appelée, un nouvel environment est construit.
- ~ Comme les environments sont ordonnés, cela permet l'implémentation du concept de *portée lexicale*.

Voir exemples.ipynb

→ En général, l'utilisation de variables globales devrait être évitée.

- → En général, l'utilisation de variables globales devrait être évitée.
 - → Moins portable.

- → En général, l'utilisation de variables globales devrait être évitée.
 - \leadsto Moins portable.
 - → Plus difficile à comprendre.

- → En général, l'utilisation de variables globales devrait être évitée.
 - → Moins portable.
 - → Plus difficile à comprendre.
 - → Plus difficile à déboguer.

- → En général, l'utilisation de variables globales devrait être évitée.
 - → Moins portable.
 - → Plus difficile à comprendre.
 - → Plus difficile à déboguer.
 - \leadsto Moins performant.

- → En général, l'utilisation de variables globales devrait être évitée.
 - → Moins portable.
 - → Plus difficile à comprendre.
 - → Plus difficile à déboguer.
 - → Moins performant.
- Variables globales : souvent utilisées pour modifier le comportement d'une fonction.

- → En général, l'utilisation de variables globales devrait être évitée.
 - → Moins portable.
 - → Plus difficile à comprendre.
 - → Plus difficile à déboguer.
 - → Moins performant.
- → Variables globales : souvent utilisées pour modifier le comportement d'une fonction.
- → Il existe de meilleures alternatives.

→ Par défaut, les fonctions sont déclarées dans R_GlobalEnv.

- → Par défaut, les fonctions sont déclarées dans R_GlobalEnv.
- → La seule manière de leur donner un état est de faire appel à des variables globales.

- → Par défaut, les fonctions sont déclarées dans R_GlobalEnv.
- → Pour éviter cela, il faudrait déclarer une fonction dans son propre environment.

- → Par défaut, les fonctions sont déclarées dans R_GlobalEnv.
- → La seule manière de leur donner un état est de faire appel à des variables globales.
- → Pour éviter cela, il faudrait déclarer une fonction dans son propre environment.
- → Une manière de procéder est de faire appel a une closure.

- → Par défaut, les fonctions sont déclarées dans R_GlobalEnv.
- → Pour éviter cela, il faudrait déclarer une fonction dans son propre environment.
- → Une manière de procéder est de faire appel a une closure.
- → De manière informelle, closure ≃ fonction dans une fonction.

Closure¹

- → Par défaut, les fonctions sont déclarées dans R_GlobalEnv.
- → Pour éviter cela, il faudrait déclarer une fonction dans son propre environment.
- → Une manière de procéder est de faire appel a une closure.
- → De manière informelle, closure ≃ fonction dans une fonction.
- → On exploite le fait qu'un nouvel environment est créé lors de l'appel d'une fonction.

Variable globale vs. closure

Voir exemples.ipynb

Pour beaucoup de langages de programmation (particulièrement les langages compilés),

→ Le coût de l'appel d'une fonction est négligeable.

Pour beaucoup de langages de programmation (particulièrement les langages compilés),

- → Le coût de l'appel d'une fonction est négligeable.
- → Bien diviser le code en fonction = plus de possibilités d'optimisation par le compilateur.

Pour beaucoup de langages de programmation (particulièrement les langages compilés),

- → Le coût de l'appel d'une fonction est négligeable.
- → Bien diviser le code en fonction = plus de possibilités d'optimisation par le compilateur.

Pour beaucoup de langages de programmation (particulièrement les langages compilés),

- → Le coût de l'appel d'une fonction est négligeable.
- → Bien diviser le code en fonction = plus de possibilités d'optimisation par le compilateur.

Donc, on ne se pose pas de question. Pour R,

Pour beaucoup de langages de programmation (particulièrement les langages compilés),

- → Le coût de l'appel d'une fonction est négligeable.
- → Bien diviser le code en fonction = plus de possibilités d'optimisation par le compilateur.

- → L'appel de fonction est coûteux (construction de l'environment...).
- → Il n'y a pas de possibilité d'optimisation.

Pour beaucoup de langages de programmation (particulièrement les langages compilés),

- → Le coût de l'appel d'une fonction est négligeable.
- → Bien diviser le code en fonction = plus de possibilités d'optimisation par le compilateur.

- → Il n'y a pas de possibilité d'optimisation.
- → Faut-il quand même écrire des fonctions? Absolument!

Pour beaucoup de langages de programmation (particulièrement les langages compilés),

- → Le coût de l'appel d'une fonction est négligeable.
- → Bien diviser le code en fonction = plus de possibilités d'optimisation par le compilateur.

- → Il n'y a pas de possibilité d'optimisation.
- → Faut-il quand même écrire des fonctions? Absolument!
- Toutefois, dans certaines parties critiques du code, il peut être utile d'appeler le moins de fonctions possible.

Exemple

Voir exemples.ipynb

→ Les boucles ne sont pas particulièrement lentes en R.

- → Les boucles ne sont pas particulièrement lentes en R.
 - Toutefois, le type d'algorithme implicite à l'utilisation de boucles n'est pas bien géré par R.

- → Les boucles ne sont pas particulièrement lentes en R.
 - Toutefois, le type d'algorithme implicite à l'utilisation de boucles n'est pas bien géré par R.
- → Les performances d'un programme écrit en R sont limitées.

- → Les boucles ne sont pas particulièrement lentes en R.
 - Toutefois, le type d'algorithme implicite à l'utilisation de boucles n'est pas bien géré par R.
- → Les performances d'un programme écrit en R sont limitées.
 - → Toutefois, l'objectif premier de R n'est pas la performance; on ne juge pas un poisson rouge à sa capacité à grimper dans les arbres!

- → Les boucles ne sont pas particulièrement lentes en R.
 - Toutefois, le type d'algorithme implicite à l'utilisation de boucles n'est pas bien géré par R.
- → Les performances d'un programme écrit en R sont limitées.
 - → Toutefois, l'objectif premier de R n'est pas la performance; on ne juge pas un poisson rouge à sa capacité à grimper dans les arbres!
 - → De plus, il est relativement facile d'appeler des fonctions contenues dans des librairies partagées à partir de R.

- → Les boucles ne sont pas particulièrement lentes en R.
 - Toutefois, le type d'algorithme implicite à l'utilisation de boucles n'est pas bien géré par R.
- → Les performances d'un programme écrit en R sont limitées.
 - → Toutefois, l'objectif premier de R n'est pas la performance; on ne juge pas un poisson rouge à sa capacité à grimper dans les arbres!
 - De plus, il est relativement facile d'appeler des fonctions contenues dans des librairies partagées à partir de R.
- → Un langage n'est pas meilleur qu'un autre parce qu'il est plus performant.

- → Les boucles ne sont pas particulièrement lentes en R.
 - Toutefois, le type d'algorithme implicite à l'utilisation de boucles n'est pas bien géré par R.
- → Les performances d'un programme écrit en R sont limitées.
 - → Toutefois, l'objectif premier de R n'est pas la performance; on ne juge pas un poisson rouge à sa capacité à grimper dans les arbres!
 - De plus, il est relativement facile d'appeler des fonctions contenues dans des librairies partagées à partir de R.
- → Un langage n'est pas meilleur qu'un autre parce qu'il est plus performant.
 - → On choisit un langage pour un problème particulier en fonction des objectifs qu'on souhaite atteindre.

→ Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.

- → Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.
 - Toutefois, l'appel à une librairie partagée ou l'exécution d'une commande externe a un coût qu'il ne faut pas négliger.

- → Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.
 - Toutefois, l'appel à une librairie partagée ou l'exécution d'une commande externe a un coût qu'il ne faut pas négliger.
 - De plus, le temps de développement peut augmenter drastiquement.

- → Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.
 - Toutefois, l'appel à une librairie partagée ou l'exécution d'une commande externe a un coût qu'il ne faut pas négliger.
 - → De plus, le temps de développement peut augmenter drastiquement.
- → Quelques conseils généraux pour du code performant :

- → Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.
 - Toutefois, l'appel à une librairie partagée ou l'exécution d'une commande externe a un coût qu'il ne faut pas négliger.
 - → De plus, le temps de développement peut augmenter drastiquement.
- → Quelques conseils généraux pour du code performant :
 - → Utiliser des opérations vectorisées.

- → Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.
 - Toutefois, l'appel à une librairie partagée ou l'exécution d'une commande externe a un coût qu'il ne faut pas négliger.
 - → De plus, le temps de développement peut augmenter drastiquement.
- → Quelques conseils généraux pour du code performant :
 - Utiliser des opérations vectorisées.
 - → Éviter de modifier les variables.

- → Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.
 - Toutefois, l'appel à une librairie partagée ou l'exécution d'une commande externe a un coût qu'il ne faut pas négliger.
 - → De plus, le temps de développement peut augmenter drastiquement.
- → Quelques conseils généraux pour du code performant :
 - → Utiliser des opérations vectorisées.
 - → Éviter de modifier les variables.
 - → Écrire des boucles courtes appelant peu de fonctions.

- → Il peut être utile d'implémenter certaines parties critique d'un programme R dans un autre language.
 - Toutefois, l'appel à une librairie partagée ou l'exécution d'une commande externe a un coût qu'il ne faut pas négliger.
 - → De plus, le temps de développement peut augmenter drastiquement.
- → Quelques conseils généraux pour du code performant :
 - → Utiliser des opérations vectorisées.
 - → Éviter de modifier les variables.
 - → Écrire des boucles courtes appelant peu de fonctions.
 - → Éviter les fonctions récursives.

Références

- [1] Phil JOHNSON. The most WTF-y programming languages. en. Sept. 2013. URL: https: //www.itworld.com/article/2833252/the-most-wtf-y-programming-languages.html.
- [2] TIOBE Index | TIOBE The Software Quality Company. URL: https://www.tiobe.com/tiobe-index/.
- [3] What are the Most Disliked Programing Languages? | Stack Overflow. en-US. Oct. 2017. URL: https: //stackoverflow.blog/2017/10/31/dislikedprogramming-languages/.

[4] Hadley WICKHAM. Advanced R. URL: https://adv-r.hadley.nz/.